## Programmazione dinamica (V parte)

Progettazione di Algoritmi a.a. 2021-22

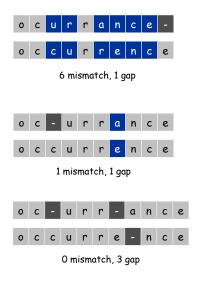
Matricole congrue a 1

Docente: Annalisa De Bonis

99

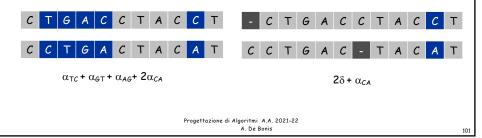
# Allineamento di sequenze

- Quanto sono simili le due stringhe seguenti?
- ocurrance
- occurrence
- Allineamo i caratteri
- Ci sono diversi modi per fare questo allineamento
- Qual e' migliore?



### Edit Distance

- Applicazioni.
- Base per il comando Unix diff.
- Riconoscimento del linguaggio.
- Biologia computazionale.
- Edit distance. [Levenshtein 1966, Needleman-Wunsch 1970]
- Gap penalty  $\delta$ ;
- Mismatch penalty  $\alpha_{pq}$ . Si assume  $\alpha_{pp}$ =0



101

## Applicazione del problema dell'allineamento di sequenze

- I problemi su stringhe sorgono naturalmente in biologia: il genoma di un organismo è suddiviso in molecole di DNA chiamate cromosomi, ciascuno dei quali serve come dispositivo di immagazzinamento chimico.
- Di fatto, si può pensare ad esso come ad un enorme nastro contenente una stringa sull'alfabeto {A,C,G,T}. La stringa di simboli codifica le istruzioni per costruire molecole di proteine: usando un meccanismo chimico per leggere porzioni di cromosomi, una cellula può costruire proteine che controllano il suo metabolismo.

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

## Applicazione del problema dell'allineamento di sequenze

- Perche` le somiglianze tra stringhe sono rilevanti in questo scenario?
- Le sequenze di simboli nel genoma di un organismo determinano le proprieta` dell'organismo.
- Esempio. Supponiamo di avere due ceppi di batteri X e Y che sono strettamente connessi dal punto di vista evolutivo.
- Supponiamo di aver determinato che una certa sottostringa nel DNA di X sia la codifica di una certa tossina.
- Se scopriamo una sottostringa molto simile nel DNA di Y, possiamo ipotizzare che questa porzione del DNA di Y codifichi un tipo di tossina molto simile a quella codificata nel DNA di X.
- Esperimenti possono quindi essere effettuati per convalidare questa ipotesi.
- Questo e` un tipico esempio di come la computazione venga usata in biologia computazionale per prendere decisioni circa gli esperimenti biologici.

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

10

103

### Allineamento di sequenze

- · Abbiamo bisogno di un modo per allineare i caratteri di due stringhe
- Formiamo un insieme di coppie di caratteri, dove ciascuna coppia e` formata da un carattere della prima stringa e uno della seconda stringa.
- Def. insieme di coppie è un matching se ogni elemento appartiene ad al più una coppia
- Def. Le coppie  $(x_i,y_j)$  e  $(x_i,y_j)$  si incrociano se i < i' ma j > j
- (x<sub>1</sub>, y<sub>2</sub>) e (x<sub>4</sub>,y<sub>3</sub>) non si incrociano

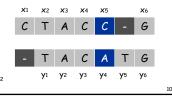
j > j'.

C T - - T

Def. Un allineamento M è un insieme di coppie  $(x_i, y_j)$  tali che

- Me' un matching
- M non contiene coppie che si incrociano

Esempio: CTACCG **VS.** TACATG Allineamento:  $M = (x_2,y_1), (x_3,y_2), (x_4,y_3), (x_5,y_4), (x_6,y_6).$ 



Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

### Allineamento di sequenze

• Obiettivo: Date due stringhe  $X = x_1 x_2 ... x_m$  e  $Y = y_1 y_2 ... y_n$  trova l'allineamento di minimo costo.

$$cost(M) = \underbrace{\sum_{(x_i, y_j) \in M} \alpha_{x_i y_j}}_{\text{mismatch}} + \underbrace{\sum_{i: x_i \text{ unmatched}} \delta + \sum_{j: y_j \text{ unmatched}} \delta}_{\text{gap}}$$

- · Affermazione.
- Dato un allineamento M di due stringhe  $X = x_1 x_2 ... x_m$  e  $Y = y_1 y_2 ... y_n$ , se in M non c'è la coppia  $(x_m, y_n)$  allora o  $x_m$  non e` accoppiato in M o  $y_n$  non e` accoppiato in M.
- Dim. Supponiamo che x<sub>m</sub> e y<sub>n</sub> sono entrambi accoppiati ma non tra di loro. Supponiamo che x<sub>m</sub> sia accoppiato con y<sub>j</sub> e y<sub>n</sub> sia accoppiato con x<sub>i</sub>. In altre parole M contiene le coppie (x<sub>m</sub>,y<sub>j</sub>) e (x<sub>i</sub>,y<sub>n</sub>). Siccome i×m ma n>j allora si ha un incrocio e ciò contraddice il fatto che M è allineamento.

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

10

105

## Allineamento di sequenze: struttura del problema

- Def. OPT(i, j) = costo dell'allineamento ottimo per le due stringhe  $x_1 x_2 ... x_i$  e  $y_1 y_2 ... y_j$ .
- Caso 1: x<sub>i</sub> e y<sub>j</sub> sono accoppiati nella soluzione ottima per x<sub>1</sub> x<sub>2</sub> ... x<sub>i</sub> e y<sub>1</sub> y<sub>2</sub> ... y<sub>j</sub>
   OPT(i, j) = Costo dell'eventuale mismatch tra x<sub>i</sub> e y<sub>j</sub> + costo dell'allineamento ottimo di x<sub>1</sub> x<sub>2</sub> ... x<sub>i-1</sub> and y<sub>1</sub> y<sub>2</sub> ... y<sub>j-1</sub>
- Caso 2a: x<sub>i</sub> non e` accoppiato nella soluzione ottima per x<sub>1</sub> x<sub>2</sub> ... x<sub>i</sub> e y<sub>1</sub> y<sub>2</sub> ... y<sub>j</sub>
   OPT(i, j) = Costo del gap x<sub>i</sub> + costo dell'allineamento ottimo di x<sub>1</sub> x<sub>2</sub> ... x<sub>i-1</sub> e y<sub>1</sub> y<sub>2</sub> ... y<sub>j</sub>
- Case 2b:  $y_j$  non e` accoppiato.nella soluzione ottima per  $x_1 x_2 \dots x_i$  e  $y_1 y_2 \dots y_j$  OPT(i, j) = Costo del gap  $y_j$  + costo dell'allineamento ottimo di  $x_1 x_2 \dots x_i$  e  $y_1 y_2 \dots y_{j-1}$

$$OPT(i,j) = \begin{cases} j\delta & \text{se } i = 0 \\ \min \begin{cases} \alpha_{x_i y_j} + OPT(i-1,j-1) \\ \delta + OPT(i-1,j) & \text{altrimenti} \\ \delta + OPT(i,j-1) & \text{se } j = 0 \end{cases}$$

### Allineamento di sequenze: algoritmo

```
Sequence-Alignment(m, n, \mathbf{x}_1\mathbf{x}_2\ldots\mathbf{x}_m, y_1y_2\ldots y_n, \delta, \alpha) {
    for i = 0 to m
        \texttt{M[i, 0]} = \texttt{i}\delta
    for j = 0 to n

M[0, j] = j\delta
    for i = 1 to m
         for j = 1 to n
            M[i, j] = min(\alpha[x_i, y_j] + M[i-1, j-1],
                                   \delta + M[i-1, j],
                                   \delta + M[i, j-1])
    return M[m, n]
}
```

- Analisi. Tempo e spazio  $\Theta(mn)$ .
- Parole inglesi:  $m, n \le 10$ .
- Applicazioni di biologia computazionale: m = n = 100,000.
- Quindi mxn=10 miliardi . OK per il tempo ma non per lo spazio (10GB)

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

107

## Sottosequenza crescente piu` lunga elementi non necessariamente contigui

- Vogliamo individuare la sottosequenza (strettamente) crescente piu` lunga in una sequenza di numeri. La sottosequenza non deve essere necessariamente formata da elementi contigui nella sequenza input. La sequenza input è memorizzata in un array A.
- Indichiamo con A[0,...,i] il segmento di A degli elementi con indice da 0 a i.
- Esempio: A=<3 12 9 4 12 5 8 11 6 13 10>
- La sottosequenza crescente piu` lunga e` <3 4 5 8 11 13>

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

## Sottosequenza crescente piu` lunga elementi non necessariamente contigui

- OPT(i) = lunghezza della sottosequenza crescente più lunga che termina in i (l'ultimo elemento della sottosequenza è A[i])
- Una volta che abbiamo calcolato OPT(i) per ogni i, andiamo a
  calcolare il massimo di tutti i valori OPT(i) per ottenere la
  lunghezza della sottosequenza crescente piu` lunga.

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

109

## Sottosequenza crescente piu` lunga elementi non necessariamente contigui

- Osserviamo che nella sottosequenza crescente piu` lunga che termina in i, l'elemento A[i] e` preceduto dalla piu` lunga sottosequenza crescente che termina in un certo j tale che jxi e A[j]x[A[i].
  - · Quale di questi j bisogna prendere?
    - Quello per cui la lunghezza della sottosequenza è massima, cioe` l'indice j per cui si ottiene il massimo valore OPT(j) in questo insieme: {
       OPT(j): 0 ≤ j ≤ i-1 e A[j]<A[i]}</li>

Si ha quindi

 $OPT(i)=max{OPT(j)+1: 0 \le j \le i-1 \ e \ A[j] < A[i]}$ 

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

## Sottosequenza crescente piu`lunga elementi non necessariamente contigui Esempio: A=<3 12 9 4 12 5 8 11 6 13 10> per calcolare OPT(10) consideriamo j=0, j=2, j=3, j=5, j=6, j=8 per calcolare OPT(9) consideriamo j=0, j=2, j=3,j=4 j=5, j=6,j=7,j=8 per calcolare OPT(8) consideriamo j=0, j=3,j=5 per calcolare OPT(7) consideriamo j=0, j=2, j=3, j=5, j=6 per calcolare OPT(6) consideriamo j=0, j=3, j=5, per calcolare OPT(5) consideriamo j=0, j=3 per calcolare OPT(4) consideriamo j=0, j=2, j=3 per calcolare OPT(3) consideriamo j=0 per calcolare OPT(2) consideriamo j=0 per calcolare OPT(1) consideriamo j=0 $OPT(0)=1 \rightarrow OPT(1)=OPT(2)=OPT(3)=2$ $OPT(0)=1 e OPT(2)=OPT(3)=2 \rightarrow OPT(4)=3$ $OPT(0)=1 e OPT(3)=2 \rightarrow OPT(5)=3$ OPT(0)=1, OPT(3)=2, $OPT(5)=3 \rightarrow OPT(6)=4$ OPT(0)=1, OPT(2)=OPT(3)=2, OPT(5)=3, $OPT(6)=4 \rightarrow OPT(7)=5$ OPT(0)=1, OPT(3)=2, OPT(5)= 3 --> OPT(8)=4 OPT(0)=1, OPT(2)=OPT(3)=2, OPT(4)=3, OPT(5)=3, OPT(6)=4, $OPT(7)=5 \rightarrow$ OPT(9)=6 OPT(0)=1 e OPT(3)=2 , OPT(5)= 3, OPT(6)=OPT(8)=4 $\rightarrow$ OPT(10)=5 Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

111

#### Sottosequenza crescente piu` lunga elementi non necessariamente contigui Questo algoritmo trova la lunghezza della sottosequenza crescente piu`lunga che termina in i LIS(A,i): M globale if i<0 return 0 P globale: mi serve per la stampa tempo $O(n^2)$ P[i]= indice dell'elemento che precede i if i=0 nella sottosequenza crescente piu` lunga P[0]=-1, M[0]=1, return 1 che termina in i if M[i]!=empty return M[i]M[i]=1 //restera` 1 se non ci sono j<i conA[j]<br/>\*A[i]P[i]=-1 //serve nel caso alla fine M[i]=1 for( j=0; j<i; j++) m=LIS(A,j)Per computare il valore della sottosequenza crescente if (A[j]<A[i] && M[i]<m+1) piu` lunga dell'array occorre prima invocare LIS(A,n-1) e poi trovare il massimo dell'array M. M[i]=m+1 P[i]=j return M[i] Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

## Sottosequenza crescente piu` lunga elementi non necessariamente contigui

Analisi dell'algoritmo ricorsivo:

- Sia 1 ≤ i<n. Se escludiamo il tempo per le chiamate ricorsive al suo intermo LIS(A,i) richiede tempo O(i) se M[i] è vuoto e O(1) altrimenti. LIS(A,i) viene invocata in tutte le chiamate LIS(A,k) con i<k<n, e quindi in totale n-i-1 volte ma solo la prima volta richiede tempo O(i). Quindi tutte le chiamate a LIS(A,i) richiedono in totale tempo O(n).
- 2. LIS(A,0) viene invocata in tutte le chiamate LIS(A,k) con 0 < k < n e ogni volta richiede O(1). Quindi il tempo delle n-1 chiamate a LIS(0) è O(n).
- Dalla 1 e dalla 2 il tempo per eseguire tutte le chiamate a LIS(A,i) per ciascun 0≤ i ≤ n-1 è O(n) per un tempo totale pari a O(n²)

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

113

## Sottosequenza crescente piu` lunga elementi non necessariamente contigui

Questo algoritmo stampa la sottosequenza crescente piu` lunga. Indichiamo con max l'indice in cui si trova l'elemento massimo di M, cioe` M[max]=max{OPT(i): 0<=i<=n-1}

```
PrintLIS(A,i):

if i >= 0

PrintLis(A,P[i])

print(A[i])
```

prima chiamata con i=max

M e P costruiti in precedenza

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

#### Sottosequenza crescente piu` lunga elementi non necessariamente contigui Questa e` la versione iterativa dell'algoritmo LIS 1. ITLIS(A) n = A.lengthfor i=0 to n-1 M[i]=1 P[i]=-1 5 for i=0 to n-1 //ogni iterazione computa OPT(i), i=0,...,n-1 7. for j = 0 to i-1 //ogni iterazione computa OPT(j) , j<i e A[j]<A[i] if (A[j] < A[i])8. 9. if M[j] + 1 > M[i] 10. M[i]=M[j]+1M[i]=lunghezza sottosequenza crescente 11. P[i]=j piu` lunga che termina in A[i] P[i]= indice predecessore di A[i] nella 12. max= M[0] sottosequenza crescente piu` lunga che 13. for i=0 to n-1 termina in A[i] 14. if M[i]>max 15. max=A[i]16. return max

115

## Sottosequenza crescente piu` lunga elementi non necessariamente contigui

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

• Esempio: A=<3 12 9 4 12 5 8 11 6 13 10>

	3	12	9	4	12	5	8	11	6	13	10
M	1	2	2	2	3	3	4	5	4	6	5
Р	-1	0	0	0	3	3	5	6	5	7	8

- Per aggiornare M[1] nel for esterno (linea 6) consideriamo solo A[0] nel for interno (linea 7):
  - $\max\{M[1],M[0]+1\}=\{1,2\}=2$
- Per aggiornare M[2] nel for esterno (linea 6) consideriamo A[0] e A[1] nel for interno (linea 7) ma A[0] è l'unico < A[2]:</li>
  - max{M[2],M[0]+1}={1,2}=2
- Per aggiornare M[3] nel for esterno (linea 6) consideriamo A[0], A[1] e A[2] nel for interno (linea 7) ma A[0] è l'unico < A[3]:</li>
  - max{M[3],M[2]+1}={1,2}=2
- Per aggiornare M[4] nel for esterno (linea 6) consideriamo A[0] , A[1], A[2] e A[3] nel for interno (linea 7). Tra questi solo A[0], A[2] e A[3] sono < A[4]:
  - max{M[4],M[0]+1,M[2]+1, M[3]+1}={1,2,3}=3
- Per aggiornare M[5] nel for esterno (linea 6) consideriamo A[0], ..., A[4] nel for interno (linea 7). Tra
  questi solo A[0] e A[3] sono < A[5]:</li>
  - max{M[5],M[0]+1,M[3]+1}={1,2,3}=3
- ecc.

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

#### Parentesizzazione di valore massimo

- Si scriva un algoritmo che trova il valore massimo ottenibile con una parentesizzazione completa della seguente espressione:  $x_1/x_2/.../x_{n-1}/x_n$
- Una parentesizzazione completa di  $x_1/x_2/.../x_{n-1}/x_n$  si ottiene racchiudendo ciascun '/' insieme alle due sottoespressioni a cui esso si applica tra una coppia di parentesi. La coppia di parentesi piu` esterna puo` essere omessa.
- Ad esempio: le parentesizzazioni complete di 24/6/2 sono
   I. (24/6)/2=2, II. 24/(6/2)=8. La II produce il valore massimo
- Un approccio potrebbe essere quello di considerare tutti i possibili modi di parentesizzare l'espressione e di calcolare il valore dell'espressione risultante.
  - Questo approccio e` inefficiente perche` il numero di parentesizzazioni complete e` esponenziale.

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

117

#### Parentesizzazione di valore massimo

- Il costo C(P) di una parentesizzazione P e` il valore dell'espressione quando le divisioni sono eseguite nell'ordine dettato dalle parentesi nella parentesizzazione.
- Ad esempio: 24/6/2

I. (24/6)/2=2, II. 24/(6/2)=8

2 e` il costo della I parentesizzazione; 8 e` il costo della II parentesizzazione

Progettazione di Algoritmi A.A. 2021-2 A. De Bonis

#### Parentesizzazione di valore massimo

- Soluzione basata sulla programmazione dinamica.
- Sia ikj e sia P(i,...,j) una parentesizzazione della sottoespressione x<sub>i</sub>/x<sub>i+1</sub>/.../x<sub>j</sub>. Supponiamo che questa parentesizzazione a livello piu` esterno sia formata da una certa parentesizzazione P(i,...,k) di x<sub>i</sub>/x<sub>i+1</sub>/.../x<sub>k</sub> e una certa parentesizzazione P(k+1,...,j) di x<sub>k+1</sub>/x<sub>k+2</sub>/.../x<sub>j</sub>, per un certo ik k ≤ j-1
- Il costo C(P(i,...,j)) di P(i,...,j) e` quindi C(P(i,...,k)) / C(P(k+1,...,j))
- Esempio: la parentesizzazione ((100/5)/20)/(15/3) contiene a livello piu` esterno le parentesizzazioni ((100/5)/20) e (15/3) mentre (100/5)/(20/(15/3)) contiene a livello piu` esterno le parentesizzazioni (100/5) e (20/(15/3)).

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

119

### Parentesizzazione di valore massimo

- MAX(i, j) = costo massimo di una parentesizzazione per la sottoespressione  $x_i/x_{i+1}/.../x_j$
- min(i,j) = costo minimo di una parentesizzazione per la sottoespressione  $x_i/x_{i+1}/.../x_j$
- Sia P'(i,...,j) la parentesizzazione di  $x_i/x_{i+1}/.../x_j$  di costo massimo
- A livello piu` esterno, P'(i,...,j) contiene una certa parentesizzazione
  P'(i,...,k) di x<sub>i</sub>/x<sub>i+1</sub>/.../x<sub>k</sub> e una certa parentesizzazione P'(k+1,...,j) di
  x<sub>k+1</sub>/x<sub>k+2</sub>/.../x<sub>j</sub>, per un certo intero k compreso tra i e j-1.
- P'(i,...,j) e` di costo massimo se e solo se P'(i,...,k) e` la parentesizzazione di costo massimo di  $x_i/x_{i+1}/.../x_k$  e P'(k+1,...,j) e` la parentesizzazione di costo minimo di  $x_{k+1}/x_{k+2}/.../x_i$ .
  - si ha quindi MAX(i,j) = MAX(i,k) / min(k+1,j) per un certo k,  $1 \le k \le j-1$
- Siccome non sappiamo in corrispondenza di quale indice k compreso tra i e
  j-1 si ottiene la parentesizzazione di costo massimo di x<sub>i</sub>/x<sub>i+1</sub>/.../x<sub>j</sub> allora
  dobbiamo calcolare il massimo su tutti i k compresi tra i e j-1 di
  MAX(i,k)/min(k+1,j).

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

#### Parentesizzazione di valore massimo

- Ho bisogno anche di una formula per min(i,j)
- Sia P"(i,...,j) la parentesizzazione di  $x_i/x_{i+1}/.../x_j$  di costo minimo
- A livello piu` esterno, P"(i,...,j) contiene una certa parentesizzazione P"(i,...,k) di  $x_i/x_{i+1}/.../x_k$  e una certa parentesizzazione P"(k+1,...,j) di  $x_{k+1}/x_{k+2}/.../x_{j}$  per un certo intero k compreso tra i e j-1.
- P"(i,...,j) e` di costo minimo se e solo se P"(i,...,k) e` la parentesizzazione di costo minimo di  $x_i/x_{i+1}/.../x_k$  e P"(k+1,...,j) e` la parentesizzazione di costo massimo di  $x_{k+1}/x_{k+2}/.../x_j$ .
  - si ha quindi che min(i,j) = min(i,k) /MAX(k+1,j)
- Siccome non sappiamo in corrispondenza di quale indice k compreso tra i e j-1 si ottiene la parentesizzazione di costo minimo di  $x_i/x_{i+1}/.../x_j$  allora dobbiamo calcolare il minimo su tutti i k compresi tra i e j-1 di min(i,k)/MAX(k+1,j).

Progettazione di Algoritmi A.A. 2021-22 A. De Bonis

121

```
Esercizio
                                                                                M[i,j]=MAX(i,j)
                                                                                m[i,j]=min(i,j)
CatenaDiDivisioni (x) // x array t.c. x[i]=x_i
 n=length(x)
 for i=1 to n
    M[i, i]=m[i, i]=x[i]
 for lung=2 to n //ogni iterazione calcola M[i,j] ed m[i,j] per
    //i,j tali che i<j e j-i=lung
  for i=1 to n-lung+1
     j=i+lung-1
    M[i, j]=0
                                                                         O(n^3)
    m[i, j]=∞
    for k=i toj-1
                                                              vengono calcolati M[i,j] e m[i,j]
                                                              per ogni (i,j), con i<j, in questo ordine:
        vM = M[i, k]/m[k+1, j]
                                                              (1,2),(2,3), ...,(n-1,n)
(1,3),(2,4),...,(n-2,n)
        vm = m[i, k]/M[k+1, j]
       if vM > M[i, j] then M[i, j]=vM
                                                              (1,n-1),(2,n)
(1,n)
       if vm < m[i, j] then m[i, j] = vm
 return M[1, n]
```